

## Les grammaires

(Système générateur de langage)

**Définition :** Une grammaire est un moyen permettant de décrire la construction des mots d'un langage

**Définition formelle :** On appelle grammaire le quadruplet  $(V, N, X, R)$

- **V** : est un ensemble fini de symboles dits **terminaux**, (vocabulaire terminal) ;
- **N** : est un ensemble fini (disjoint de V) de symboles dits non-terminaux
- **S** : un non-terminal particulier appelé axiome (point de départ de la dérivation) ;
- **R** : est un ensemble de règles de productions de la forme  $\alpha \rightarrow \beta$  tel que  $\alpha \in (V + N)^+$  et  $\beta \in (V + N)^*$ .

La notation  $\alpha \rightarrow \beta$  est appelée une dérivation et signifie que  $\alpha$  peut être remplacé par  $\beta$ .

**NB**

- On utilisera les lettres majuscules pour les non-terminaux, et les lettres minuscules pour représenter les terminaux.
- Les règles de la forme  $\varepsilon \rightarrow \alpha$  sont *interdites*.
- Soit une suite de dérivation :  $w_1 \rightarrow w_2 \rightarrow w_3 \rightarrow \dots \rightarrow w_n$  alors on écrira :  $w_1 \rightarrow^* w_n$ .  
On dit alors qu'il y a une chaîne de **dérivation** qui mène de  $w_1$  vers  $w_n$ .

**Exemple :** Soit la grammaire

$G = (\{a\}, \{S\}, S, \{S \rightarrow aS | \varepsilon\})$ . On peut construire la chaîne de dérivation suivante :

$S \rightarrow aS \rightarrow aaS \rightarrow aaaS \dots$

### Les mots générés par une grammaire

Soit une grammaire  $G = (V, N, S, R)$ .

On dit que le mot  $u \in V^*$  est **dérivé** (ou bien **généré**) à partir de **G** s'il existe une suite de dérivation qui, partant de l'axiome **S**, permet d'obtenir **u**, noté ' $S \rightarrow^* u$ '

### Le langage engendré par une grammaire

- Le langage engendré par une grammaire G est l'ensemble de tous les mots générés par la grammaire G est noté  $L(G)$ .
- Deux grammaires G et G' sont équivalentes si  $L(G) = L(G')$ .

**Exemple :** Soit la grammaire  $G = (\{a, b\}, \{S, T\}, S, \{S \rightarrow aS | aT, T \rightarrow bT | b\})$ .

Elle génère les mots abb et aab parce que

$S \rightarrow aT \rightarrow abT \rightarrow abb$

$S \rightarrow aS \rightarrow aaT \rightarrow aab$ .

.....

$S \rightarrow aS \rightarrow aaT \rightarrow aaT \rightarrow aaaT \rightarrow \dots \rightarrow aaa \dots aT$ .

On peut facilement voir alors que le langage généré par cette grammaire est : tous les mots sur  $\{a, b\}$  de la forme  $a^m b^n$  avec  $m, n > 0$ .

### Classification de Chomsky

Comment mesurer la complexité d'une grammaire ou d'un langage ?

- Noam Chomsky remarquer que la complexité d'une grammaire (et celle du langage aussi) **dépend** de la *forme des règles* de production
- Chomsky a ainsi proposé **quatre** classes (hiérarchiques) de grammaires (et de langages) de sorte qu'**une grammaire de type i génère un langage de type j tel que  $j \geq i$** .

Soit  $G = (V, N, S, R)$  une grammaire, les classes de grammaires de Chomsky sont :

- **Type 3** ou **grammaire régulière** (à droite 1) : toutes les règles de production sont de la forme  $\alpha \rightarrow \beta$  où  $\alpha \in N$  et  $\beta = aB$  / tel que  $a \in V^*$  et  $B \in N \cup \{\epsilon\}$  ;
- **Type 2** ou **grammaire hors-contexte** : toutes les règles de production sont de la forme  $\alpha \rightarrow \beta$  où  $\alpha \in N$  et  $\beta \in (V + N)^*$  ;
- **Type 1** ou **grammaire contextuelle** : toutes les règles sont de la forme  $\alpha \rightarrow \beta$  tel que  $\alpha \in (N + V)^+$ ,  $\beta \in (V + N)^*$  et  $|\alpha| \leq |\beta|$ . De plus, si  $\epsilon$  apparaît à droite alors la partie gauche doit seulement contenir  $S$  (l'axiome).

On peut aussi trouver la définition : toutes les règles sont de la forme  $\alpha B \beta \rightarrow \alpha \omega \beta$  tel que  $\alpha, \beta \in (V + N)^*$ ,  $B \in X$  et  $\omega \in (V + N)^*$

- **Type 0** : aucune restriction. Toutes les règles sont de la forme :  $\alpha \rightarrow \beta$ ,  $\alpha \in (V + N)^+$ ,  $\beta \in (V + N)^*$

## Remarques

- Il existe une relation d'inclusion entre les types de grammaires :  
**type 3  $\subset$  type 2  $\subset$  type 1  $\subset$  type 0**
- Pour trouver la classe d'un langage on procède cependant comme suit :
  - Chercher une grammaire de type 3 qui le génère, si elle existe, le langage est de type 3 (ou **régulier**)
  - Sinon, chercher une grammaire de type 2 qui le génère, si elle existe, le langage est de type 2 (ou **algébrique**)
  - Sinon, chercher une grammaire de type 1 qui le génère, si elle existe, le langage est de type 1 (ou **contextuel**)
  - Sinon, le langage est de type 0.

## Exercice 01 :

Soient les grammaires  $G_i = (\{a, b, c\}, \{S, A, B, R, T\}, S, P_i)$ , ( $i=1, \dots, 8$ ) ; où les  $P_i$  sont :

- $P_1 : S \rightarrow aA \mid bB ; A \rightarrow a \mid ab ; B \rightarrow b \mid cb$
- $P_2 : S \rightarrow bA ; A \rightarrow aA \mid \epsilon$
- $P_3 : S \rightarrow aAb \mid \epsilon ; A \rightarrow aSb ; Ab \rightarrow \epsilon$
- $P_4 : S \rightarrow AB \mid aS \mid a ; A \rightarrow Ab \mid \epsilon ; B \rightarrow AS$
- $P_5 : S \rightarrow OS \mid 1B ; B \rightarrow 0C \mid 1S \mid \epsilon, C \rightarrow 0B \mid 1C$
- $P_6 : S \rightarrow 0X ; X \rightarrow S1 ; S \rightarrow \epsilon$
- $P_7 : S \rightarrow \epsilon \mid a \mid abS \mid bS$
- $P_8 : S \rightarrow AB ; A \rightarrow \epsilon \mid 0 ; B \rightarrow 10B \mid C ; C \rightarrow \epsilon \mid 1$

Pour chacune des grammaires  $G_i$  ( $i=1, \dots, 8$ ) ; donner le type de celle-ci, puis trouver le langage engendré par chacune d'elles.

## Exercice 02

Pour chacun des langages suivants, donner une grammaire qui l'engendre :

- |  |   |
|--|---|
| a) $L_1 = \{ 0^{2n} / n \geq 0 \}$                 | f) $L_6 = \{ a^m b^n a^n b^m / n \geq 1, m \geq 1 \}$   |
| b) $L_2 = \{ 0^n 1^n / n \geq 0 \}$                | g) $L_7 = \{ w \in \{a, b\}^* /  w  \equiv 0[3] \}$     |
| c) $L_3 = \{ a^n b^{2n} / n \geq 0 \}$             | h) $L_8 = \{ 0^i 1^j / i \geq j \geq 0 \}$              |
| d) $L_4 = \{ a^n b^m c^{n-m} / n \geq m \geq 0 \}$ | i) $L_9 = \{ 0^i 1^j / i \neq j, i \geq 0, j \geq 0 \}$ |
| e) $L_5 = \{ \text{palindromes de } \{a, b\}^* \}$ | j) $L_{10} = \{ ab^n a / n \geq 0 \}$                   |