



THÉORIES DES LANGAGES

Mr,HEMIOUD

hemourad@yahoo,fr

Université de Jijel

Département d'informatique

NOTIONS FONDAMENTALES EN THÉORIE DES LANGAGES

INTRODUCTION

- La théorie des Langages est une branche fondamentale de l'Informatique théorique.
- la première question que vous allez poser :

- **Pourquoi faut-t-il étudier la théorie des Langages ?**
- **C'est quoi l'apport pour un informaticien ?**

→ Pour répondre à vos questions nous commençons ce chapitre par exposer des applications de cette théorie.

Exemple 1 : Correction d'orthographe et de grammaire dans un document Word

- Comment fonctionne un logiciel de correction d'orthographe ?
- Comment fonctionne un logiciel de correction de grammaire ?
- Si vous êtes entrain d'écrire un texte sur word, comment un mot peut être souligné en rouge ou en vert ?
- Quand est ce qu'un mot n'est pas souligné ?

Exemple2:Compilation d'un code avec le langage C

- Que se passe-t-il lorsque vous cliquez sur compiler ?
- Comment un compilateur vous présente les erreurs ?
- Le compilateur accepte tous les mots ?

INTRODUCTION

○ Je suppose que vous posez déjà la question :

Y a-t-il une solution algorithmique pour ce genre de problèmes ?

→ la Théorie des Langages propose des solutions algorithmiques pour résoudre ces questions :

- **Y a-t-il une solution algorithmique permettant de vérifier : si un mot appartient à un Langage ?**
→ Pour répondre à cette question nous pouvons faire recours aux automates.
- **Y a-t-il une solution algorithmique permettant de vérifier : si une phrase respecte les règles de grammaire ?**
→ Pour répondre à cette question nous pouvons faire une étude des règles de grammaire.

LES LANGAGES

Définitions, propriétés et notations

Plusieurs notions sont fondamentales pour pouvoir présenter la théorie des langages.

- **Définition 1 (Alphabet)** : Un alphabet (*vocabulaire*), noté A , est un ensemble fini non vide de symboles (lettres, de chiffres et/ou de symboles graphiques)
 - **Exemples d'alphabets** :
 - l'alphabet du langage des nombre binaires : $A = \{0, 1\}$
 - Langage C (quel est son alphabet ?) ;
 - Langue française (quel est son alphabet ?).

- **Définition 2 (Mot) :** Un **mot** (ou bien une chaîne), défini sur un alphabet A , est une suite finie de symboles juxtaposés de A .

- ***Exemples de mots :***

- Sur l'alphabet $A=\{a,b\}$, on peut construire les mots: $a, aa, aba\ bba, \dots$
- Sur l'alphabet $A=\{0,1\}$, on peut construire les mots: $1, 10, 110\ 101, \dots$
- Sur l'alphabet $A=\{a,b,(,),+\}$, on peut construire les mots: $a, a+a, (a)=ba, b++, \dots$

- **Définition 3 (Longueur d'un mot) :** La longueur d'un mot u défini sur un alphabet A , notée $|u|$, est le nombre de symboles qui composent u .

- La cardinalité d'un mot u par rapport à un symbole $a \in A$ (notée par $|u|_a$) est le ***nombre d'occurrence*** de a dans u .

- ***Par exemple :***

- $|abc| = 3, |1010111| = 7.$
- *Le mot dont la longueur est nulle est noté par ϵ : $|\epsilon| = 0.$*
- $|abc|_c = 1, |1010111|_1 = 5, |1010111|_0 = 2.$

- **Définition 4 (Mot vide)** : le mot vide, noté ϵ , est défini sur tous les alphabets et est le mot de longueur 0 (autrement dit, $|\epsilon| = 0$).
- **Définition 5 (A^+)** : on note A^+ l'ensemble des mots de *longueur* supérieure ou égale à 1 que l'on peut construire à partir de l'alphabet A .
- **Définition 6 (A^*)** : on note A^* l'ensemble des mots que l'on peut construire à partir de A , y compris le mot vide : $A^* = \{\epsilon\} \cup A^+$
 - **Exemple** : Soit $V = \{a, b\}$ alors :
 $A^* = \{\epsilon, a, b, aa, ab, ba, bb, aaa, aab, aba, abb, bab, bba, \dots\}$

○ Concaténation des mots

Soient u et v deux mots définis sur l'alphabet \mathcal{A} . La concaténation de u avec v est un mot w défini sur le même alphabet \mathcal{A} . w est obtenu en écrivant u suivi de v :

- $u = a_1 \dots a_n, \quad v = b_1 b_2 \dots b_m$
- $w = uv = a_1 \dots a_n b_1 b_2 \dots b_m$

- La concaténation est notée par le point, mais il peut être omis s'il n'y a pas de d'ambiguïté
- On écrira alors : $w = u.v = uv$
 - *Exemples :*

○ Propriété de la concaténation

Soient w , u et v trois mots définis sur l'alphabet A :

- $|u.v| = |u| + |v|$;
- $\forall a \in A : |u.v|_a = |u|_a + |v|_a$;
- $(u.v).w = u.(v.w)$ (la concaténation est associative) ;
- $w.\epsilon = \epsilon.w = w$ (ϵ est un élément neutre pour la concaténation) ;

○ L'exposant

L'opération $w.w$ est notée par w^2 . En généralisant, on note $w^n = w...w$ (n fois)

En particulier, l'exposant 0 fait tomber sur ε : $w^0 = \varepsilon$ (le mot w est répété 0 fois).

○ Le mot miroir

Soit $w = a_1 a_2 ... a_n$ un mot sur A . On appelle mot *miroir* de w et on le note par w^R le mot obtenu en écrivant w l'envers, c'est-à-dire que $w^R = a_n ... a_2 a_1$. Il est donc facile de voir que $(w^R)^R = w$.

- Certains mots, appelés *palindromes*, sont égaux à leur miroir ($w^R = w$). Par ailleurs, on peut facilement vérifier que : $(u.v)^R = v^R.u^R$.

○ Définition (Préfixe, suffixe et facteur) :

Soient deux mots u et v définis sur un alphabet A .

- u est un **préfixe** de v si et seulement si $\exists w \in A^*$ tel que: $uw = v$;
- u est un **suffixe** de v si et seulement si $\exists w \in A^*$ tel que: $wu = v$;
- u est un **facteur** de v si et seulement si $\exists w_1 \in A^*$, $\exists w_2 \in A^*$ tels que: $w_1uw_2 = v$.

○ Mots conjugués

Deux mots x et y sont dits conjugués s'il existe deux mots u et v tels que : $x = uv$ et $y = vu$.

Exemple

Soit le mot $x = ((acbc)^R.baca)^R$

- Donner la chaîne de caractères à laquelle x
- Quelle est la valeur de $|x|$, $|x|_a$, $|x|_b$ et $|x|_c$?
- Donner un *préfixe* de x contenant au moins deux lettres ' c '.
- Donner un *suffixe* de x contenant une seule lettre ' a '.

Notions sur les langages

NOTIONS SUR LES LANGAGES

Un **langage** sur un alphabet A est un *ensemble* de mots construits sur A . Tout langage défini sur A est donc une partie de A^* . On distingue en particulier le langage vide \emptyset (*il ne contient aucun mot*)

Exemple :

- Langage des nombre binaires définies sur l'alphabet $\{0, 1\}$ (infini) ;
- Langage des mots de longueur 2 défini sur l'alphabet $\{a, b\} = \{aa, ab, ba, bb\}$; (fini)
- Langage C (quel est son alphabet ?) ;
- Langue française (quel est son alphabet ?).

Description d'un langage :

- Un langage *fini* peut être décrit par *l'énumération* des mots qui le composent.
- Certains langages *infinis* peuvent être décrits par *l'application d'opérations* à des langages plus simples.
- Certains langages *infinis* peuvent être décrits **par un ensemble de règles appelé grammaire**
- Enfin, certains langages infinis ne peuvent pas être décrits, ni par l'application d'opérations, ni par un ensemble de règles. On parle alors de langage *indécidable*.

Exemples : donner des exemples de mots contenus dans chacun des langages

1. Le langage des nombres binaires définies sur l'alphabet $\{0, 1\}$
2. Le langage des mots de longueur 2 définis sur l'alphabet $\{0, 1\}$
 $= \{00, 01, 10, 11\}$

Les langages suivants sont définies sur l'alphabet $\{a, b\}$

3. Le langage de tous les mots *commençant* par ***a***
4. $L = \{w \in \{a, b\}^*, \text{ tel que } \mathbf{w}$ contient seulement $2b$, le reste c'est des a 's}
4. $L = \{w \in \{a, b\}^*, \text{ tel que } \mathbf{w}$ contient un nombre de ***a*** divisible par 3}
5. $L = \{w \in \{a, b\}^*, \text{ tel que } \mathbf{w}$ contient un nombre *impaire* de b
6. $L = \{w \in A^*, w$ contient $2\mathbf{b}$ consécutifs}
7. le langage des mots formés de ***n*** fois la lettre ***a*** suivi de ***n*** fois la lettre ***b***
8. Le langage des mots contenant au moins une fois la lettre ***a***

Opérations sur les langages:

Soient L , L_1 et L_2 trois langages définis sur l'alphabet A , nous définissons les opérations suivantes :

- **L'union** : notée par $+$ ou $|$ plutôt que \cup .

$$L_1 | L_2 = L_1 + L_2 = \{m \text{ tel que } m \in L_1 \vee m \in L_2\} ;$$

- **L'intersection** :

$$L_1 \cap L_2 = \{m \text{ tel que } m \in L_1 \wedge m \in L_2\} ;$$

- **Le complément** :

$$L = \{\text{tous les mots } m \text{ sur } A \text{ tel que } m \notin L\} ;$$

- **La concaténation** (opération non ensembliste) :

$$L_1.L_2 = \{m \text{ tel que } \exists u \in L_1, \exists v \in L_2 : m = uv\} ;$$

- **Exposant** (opération non ensembliste) :

$$L^n = L.L \dots L \text{ (} n \text{ fois)}$$

$$= \{m \text{ tel que } \exists u_1, u_2, \dots, u_n \in L : m = u_1 u_2 \dots u_n\}$$

- **Fermeture transitive de Kleene** (opération non ensembliste) : notée $L^* = \cup_{i \geq 0} L^i$.

En particulier, si $L = A$ on obtient A^* :
l'ensemble de tous les mots possibles sur l'alphabet A .
On peut ainsi définir un langage comme étant un sous-ensemble quelconque de A^* ;

- **Fermeture non transitive** (opération non ensembliste) :

$$L^+ = \cup_{i > 0} L^i ;$$

- **Le langage miroir** (opération non ensembliste) :

$$L^R = \{m \text{ tel que } \exists u \in L : m = u^R\}$$

○ Propriétés des langages

Soit L, L_1, L_2, L_3 quatre langages définis sur l'alphabet A :

- $L^0 = \{\epsilon\}$
- $L^1 = L$
- $L^2 = L.L$
- $L^{n+1} = L.L^n = L^n.L$
- $L^* = L^+ \cup \{\epsilon\}$;
- $L_1.(L_2.L_3) = (L_1.L_2).L_3$;
- $L_1.(L_2|L_3) = (L_1.L_2)|(L_1.L_3)$;
- $L.L \neq L$;
- $L_1.(L_2 \cap L_3) \neq (L_1 \cap L_2).(L_1 \cap L_3)$;
- $L_1.L_2 \neq L_2.L_1$;
- $(L^*)^* = L^*$;
- $L^*.L^* = L^*$;
- $L_1.(L_2.L_1)^* = (L_1.L_2)^*.L_1$;
- $(L_1|L_2)^* = (L_1^*L_2^*)^*$;
- $L_1^*|L_2^* \neq (L_1|L_2)^*$;

- L'application des divers opérateurs doit respecter des priorités bien définies comme suit : $|$, $.$, $*$